认识爬虫

什么是爬虫

- 网络爬虫是一种按照一定的规则，自动地抓取万维网信息的程序或者脚本。
- 网页中有很多的信息和数据，要想从网页中抓取信息和数据，并保存到本地，这就是网络爬虫。
- 网页一般是由HTML语言编写的，如果说我们要从网页抓取内容，其实就是在HTML中，找到相应的内容进行抓取。

例如，我们想看看百度这个主页上面的信息和内容，或者我们想看看豆瓣上的某个电影的信息或者影评。

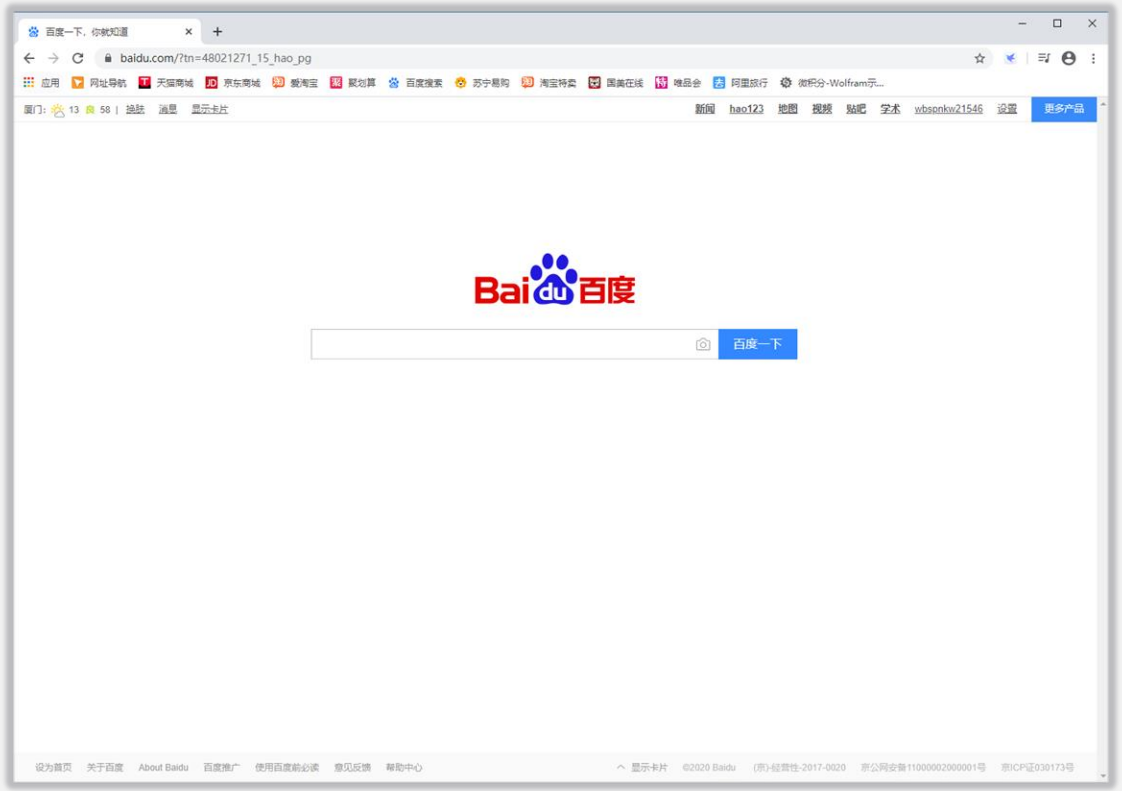

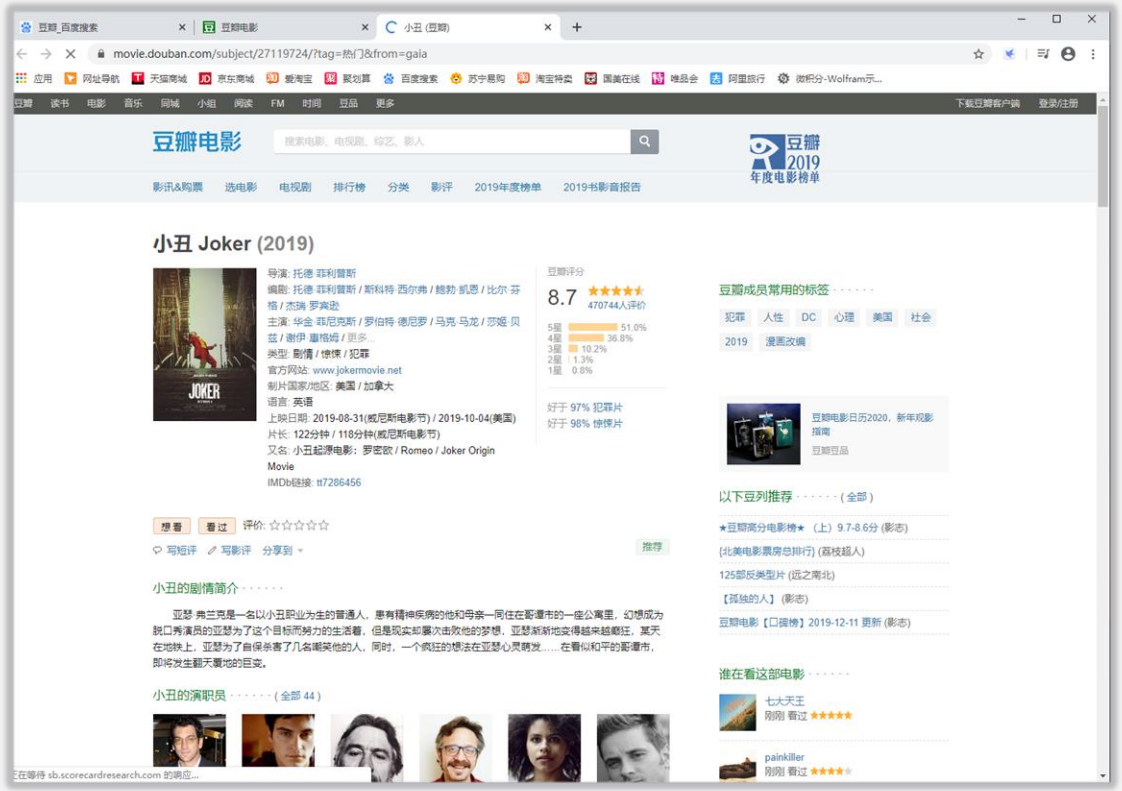

这些信息能否抓取，这些网页是如何由HTML构成的，我们在爬虫的过程中是否应该学习和掌握HTML语言呢？

认识网页和HTML

大部分的网页有三部分组成

- **HTML**（超文本标记语言）

  整个网页的结构，类似于人的骨架，它定义了你眼睛，嘴巴，鼻子的位置应该放在哪里

- **CSS**（层叠样式表）

  CSS表示样式，定义了外观，类似于人的外观细节，眼睛是双眼皮还是单眼皮，鼻子的大小等。

- **JScript**（活动脚本语言）

  Jscript表示功能，网页中的交互内容，交互特效都包含其中，类似于人的技能，你会网络爬虫，数据挖掘，数据可视化等。

我们重点的去了解**HTML**的部分。

可以说，网页是由**HTML**构成的，那么哪里可以看到网页的HTML编码呢？？？

打开Google Chrome，鼠标右击，菜单栏内选择【**检查**】，就可以看到HTML源码了。

我们观察到这里有好多的< >构成，这些我们称为**标签**。也就是说html是由标签组成的，那么这些标签有什么样的特征呢？

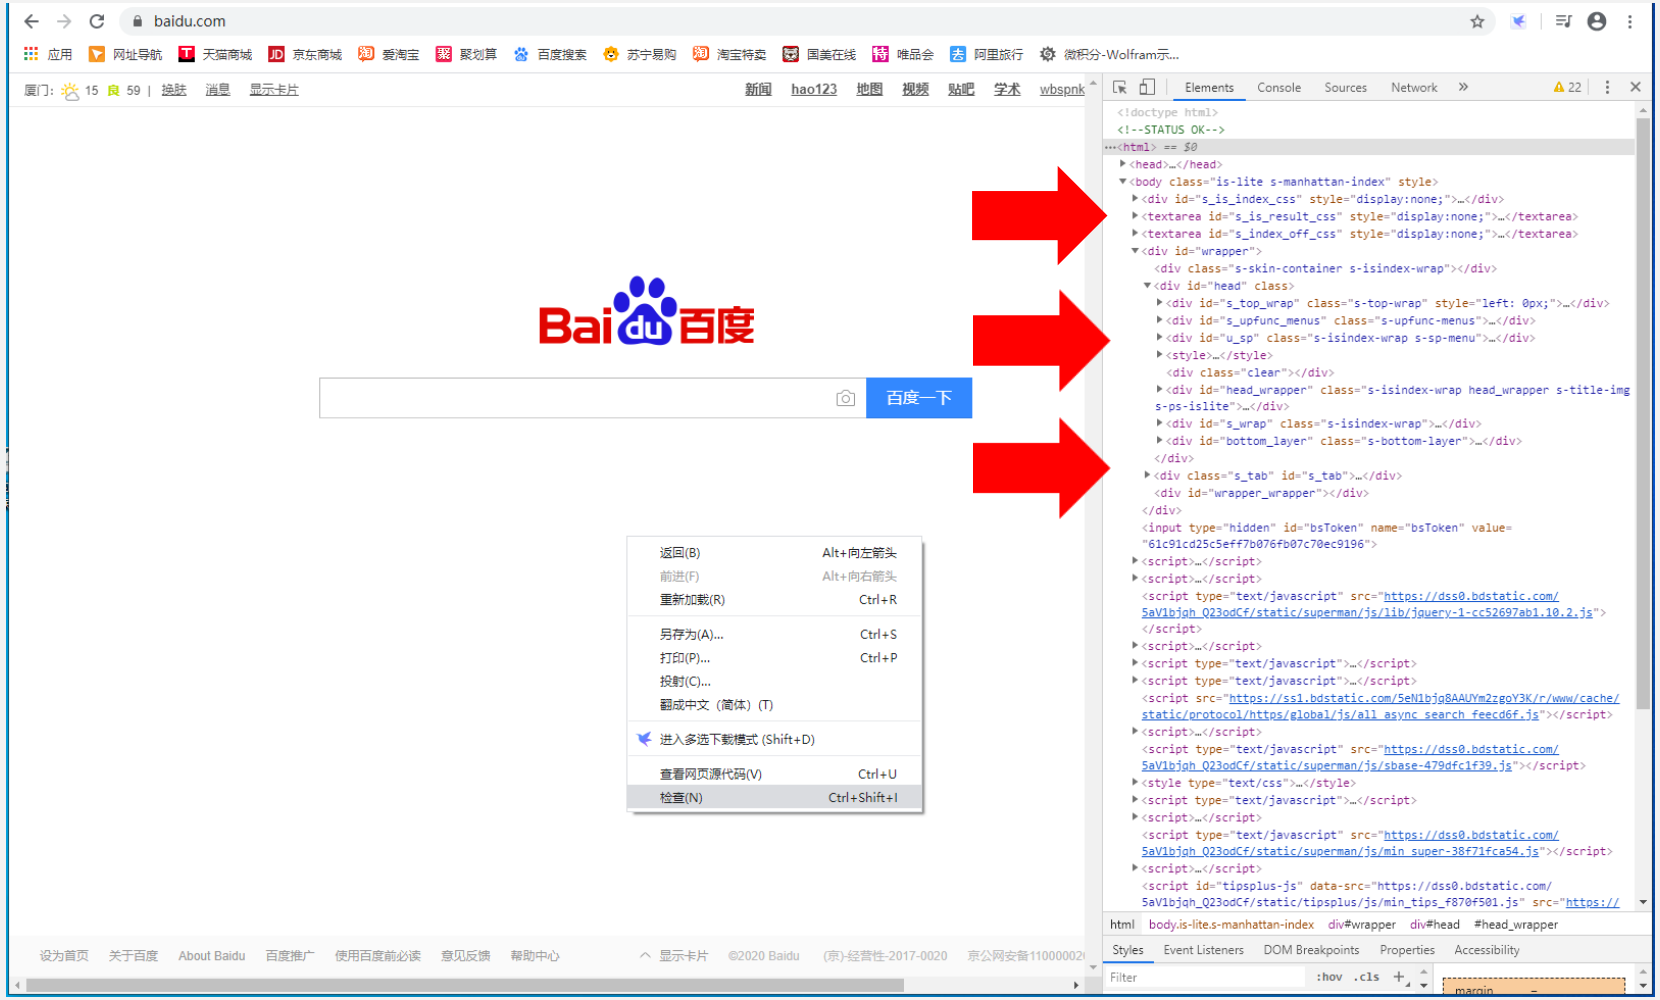

```
<!--STATUS OK--->
...<html> == $0
  ▶ <head>…</head>
  ▼ <body class="is-lite s-manhattan-index" style>
    ▶ <div id="s_is_index_css" style="display:none;">…</div>
    ▶ <textarea id="s_is_result_css" style="display:none;">…</textarea>
    ▶ <textarea id="s_index_off_css" style="display:none;">…</textarea>
    ▼ <div id="wrapper">
        <div class="s-skin-container s-isindex-wrap"></div>
      ▶ <div id="head" class>…</div>
      ▶ <div class="s_tab" id="s_tab">…</div>
        <div id="wrapper_wrapper"></div>
      </div>
      <input type="hidden" id="bsToken" name="bsToken" value=
      "61c91cd25c5eff7b076fb07c70ec9196">
    ▶ <script>…</script>
    ▶ <script>…</script>
      <script type="text/javascript" src="https://dss0.bdstatic.com/5aV1bjqh_Q23
      superman/js/lib/jquery-1-cc52697ab1.10.2.js"></script>
```

在baidu这样一个简单的网页中，我们看到标签主要有两种类型：

1、

<head> </head>

像这些是< >和</ >成对出现的标签，我们称为**闭合标签**

2、

<input >

像这些是< >**自闭和标签**

```
▼<body class="is-lite s-manhattan-index" style>
  ▶<div id="s_is_index_css" style="display:none;">…</div>
  ▶<textarea id="s_is_result_css" style="display:none;">…</textarea>
  ▶<textarea id="s_index_off_css" style="display:none;">…</textarea>
  ▼<div id="wrapper">
     <div class="s-skin-container s-isindex-wrap"></div>
    ▶<div id="head" class>…</div>
    ▶<div class="s_tab" id="s_tab">…</div>
     <div id="wrapper_wrapper"></div>
   </div>
   <input type="hidden" id="bsToken" name="bsToken" value=
   "61c91cd25c5eff7b076fb07c70ec9196">
  ▶<script>…</script>
  ▶<script>…</script>
```

在这两种标签里都有一些标签的属性

例如 id=“”，style=“ ”，class=“ ”。都表示着对应标签的属性。

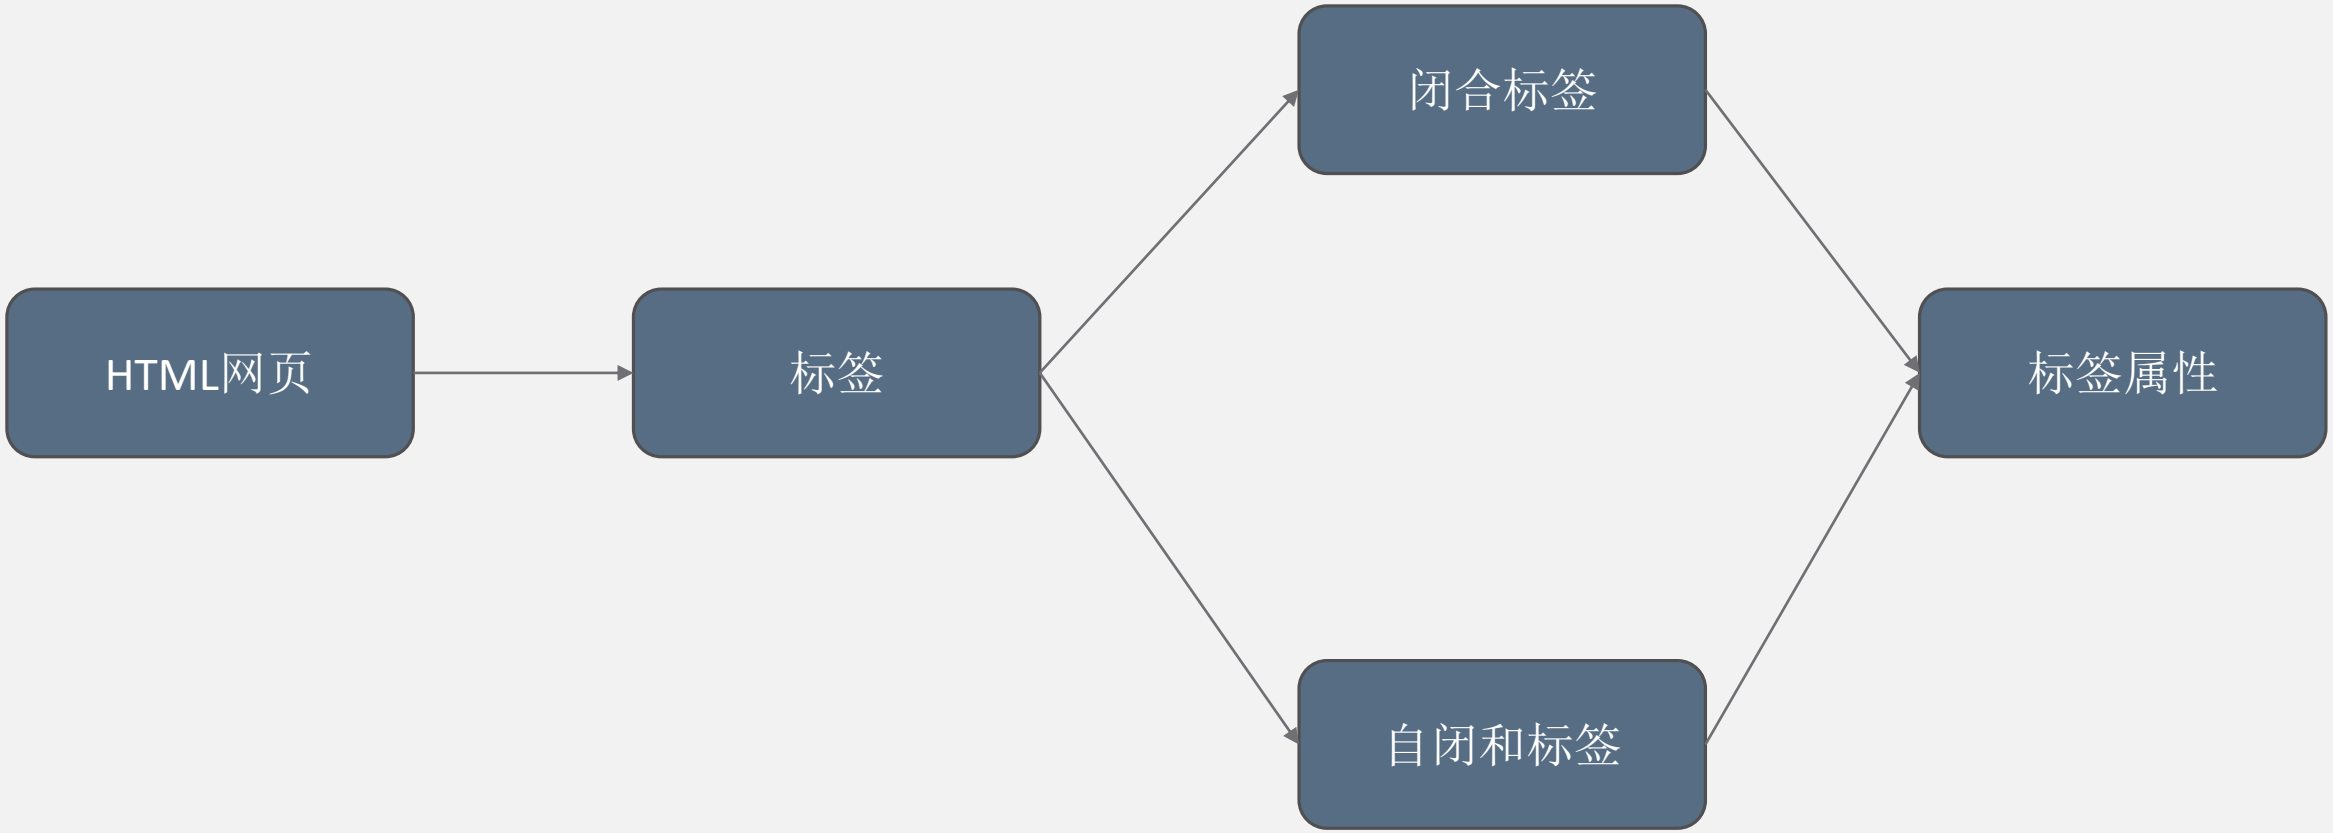

现在我们大概了解了HTML网页的结构，那么我现在遇到的问题就是如何定位到Html中我想要的数据或内容呢？

“定位”的方法

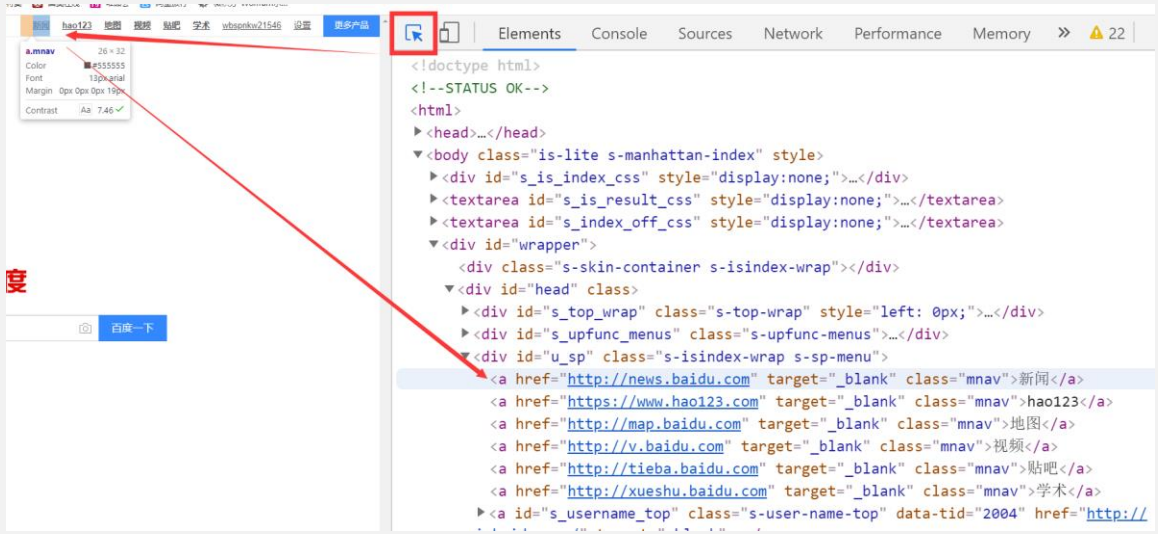

- 点击方框内的图标，再移动你的鼠标到你想找的内容上时，Html中就定位到了相应的内容了。

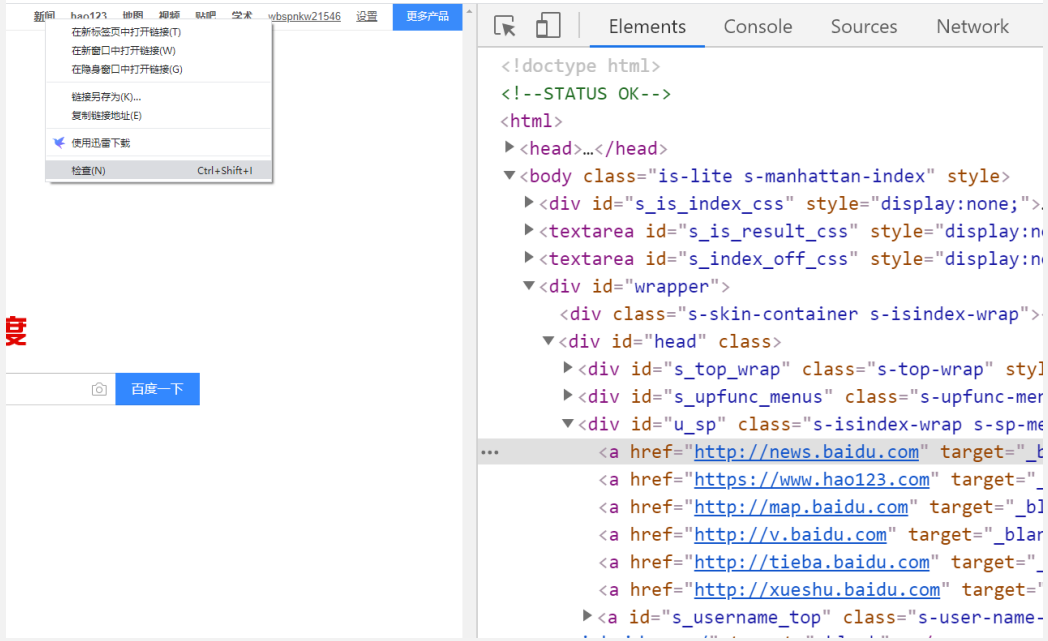

- 鼠标移动到相应内容上，点击鼠标右键，选择【检查】，HTML中同样定位到了相关内容上。

大家可以试着动手，输入一个网址，用这两种方法定位到你想看的内容到HTML中。

熟练掌握HTML页面

标签的层级关系

```
div id="wrapper">
  <div class="s-skin-container s-isindex-wrap"></
  <div id="head" class>
    ▶ <div id="s_top_wrap" class="s-top-wrap" style=
    ▶ <div id="s_upfunc_menus" class="s-upfunc-menu
    ▼ <div id="u_sp" class="s-isindex-wrap s-sp-men
        <a href="http://news.baidu.com" target="_bla
        <a href="https://www.hao123.com" target="_b
        <a href="http://map.baidu.com" target="_blan
        <a href="http://v.baidu.com" target="_blank
        <a href="http://tieba.baidu.com" target="_b
        <a href="http://xueshu.baidu.com" target="_
      ▶ <a id="s_username_top" class="s-user-name-to
```

父-子关系

了解网页的结构和层级关系能够帮助我们找到相关内容

```
▼ <div class="review-content clearfix" data-author="早睡不熬夜的白" data-url="https://movie.douban.com/review/12162158/" data-original="0">
    <p>太喜欢短评里的一句话了，如果你带着偏见去看，那你永远都不会满意。</p>
  ▶ <p>…</p>
  ▶ <p>…</p> == $0
  ▶ <p>…</p>
  ▶ <p>…</p>
    <p></p>
    <p>刚刚看完了前5集，现在已经是凌晨4点了，迫不及待来写这篇影评</p>
  ▶ <p>…</p>
  ▶ <p>…</p>
  ▶ <p>…</p>
  ▶ <p>…</p>
  ▶ <p>…</p>
  ▶ <p>…</p>
  ▶ <p>…</p>
    <p>看剧嘛，这样的最好，没有负担，没有压力，能放肆的去笑，能回忆
```

这个div标签中，所有的p标签就是所有的影评，也就是说如果我要影评数据，我只要找到div标签，定位到所有的p标签，全部爬取就好了

常见标签	用法或意义
<html>..</html>	表示标记中间的元素是网页
<body>..</body>	表示用户可见的内容
..	表示框架
..	表示段落
<li>..</li>	表示列表
<img>..</img>	表示图片
<h1>..</h1>	表示标题
<a href="“">..</a>	表示超链接

现在我们可以动手写一个简单的HTML页面，巩固一下我们对于网页结构的知识。

Step1 在桌面新建一个txt文件，打开

Step2 输入以下内容，并保存

*新建文本文档.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
<html>
<head>
        <title> Python与网络爬虫 </title>
</head>
<body>
        <div>
                <p> Python与网络爬虫入门</p>
        </div>
        <div>
                <ul>
                        <li><a href="https://www.hxxy.edu.cn/">学校主页</a></li>
                        <li>商务与管理学院</li>
                </ul>
        </div>
</body>
</html>
```

注意：1、缩进和对齐
2、字符的转换

Step3 用自己的名字和学号命名，并修改后缀名为.html，选择“是”

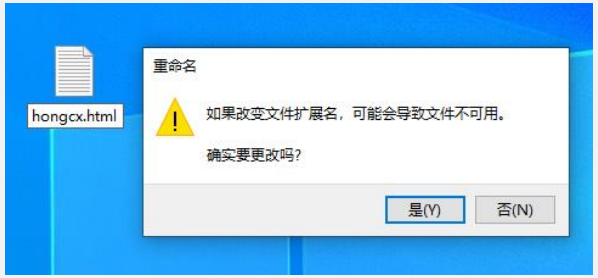

Step4 图标发生了变化，然后运行文件

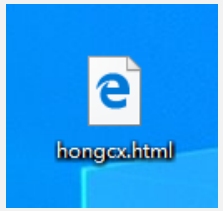

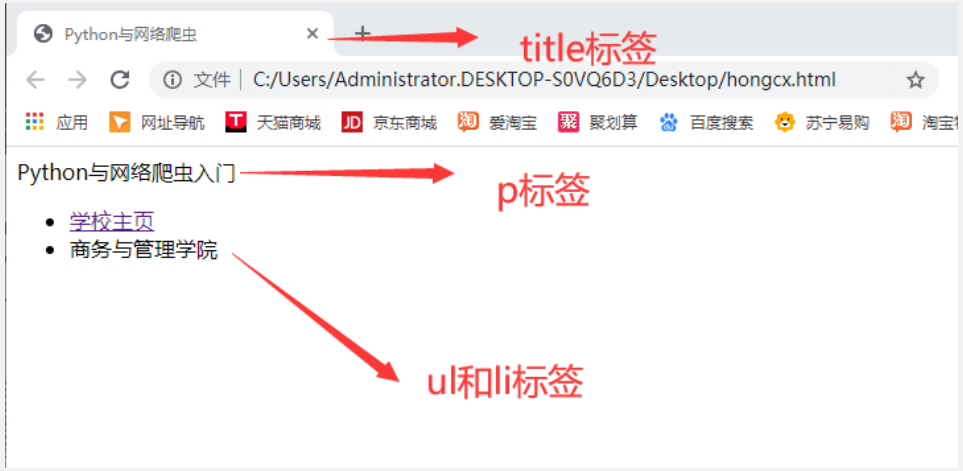

网页请求原理

我们在浏览器中输入一个网址，如www.baidu.com。得到了一个页面，这中间发生了什么？

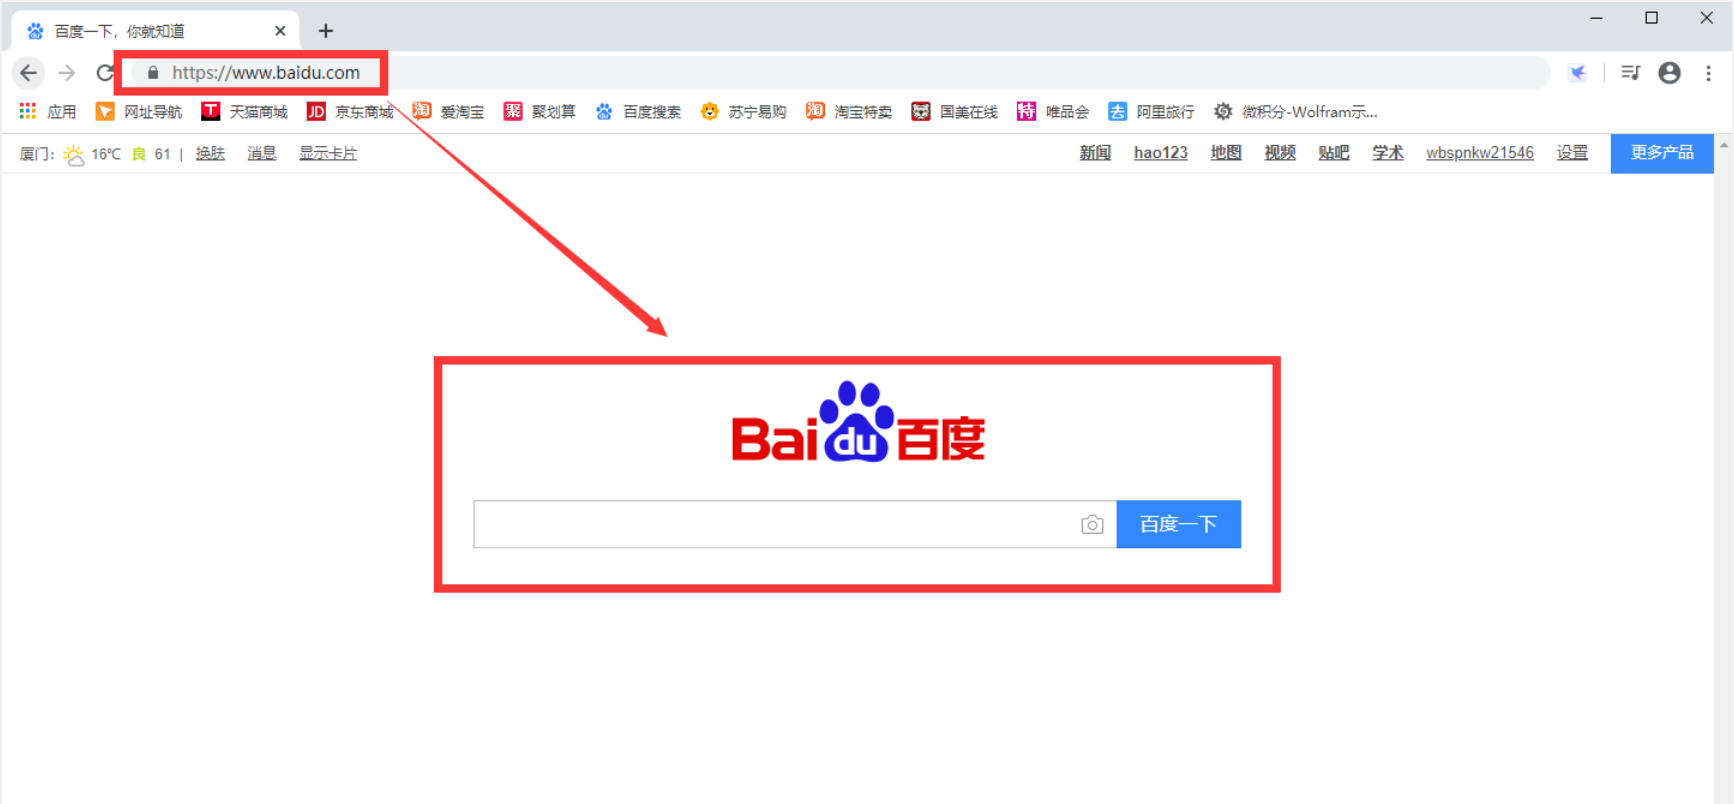

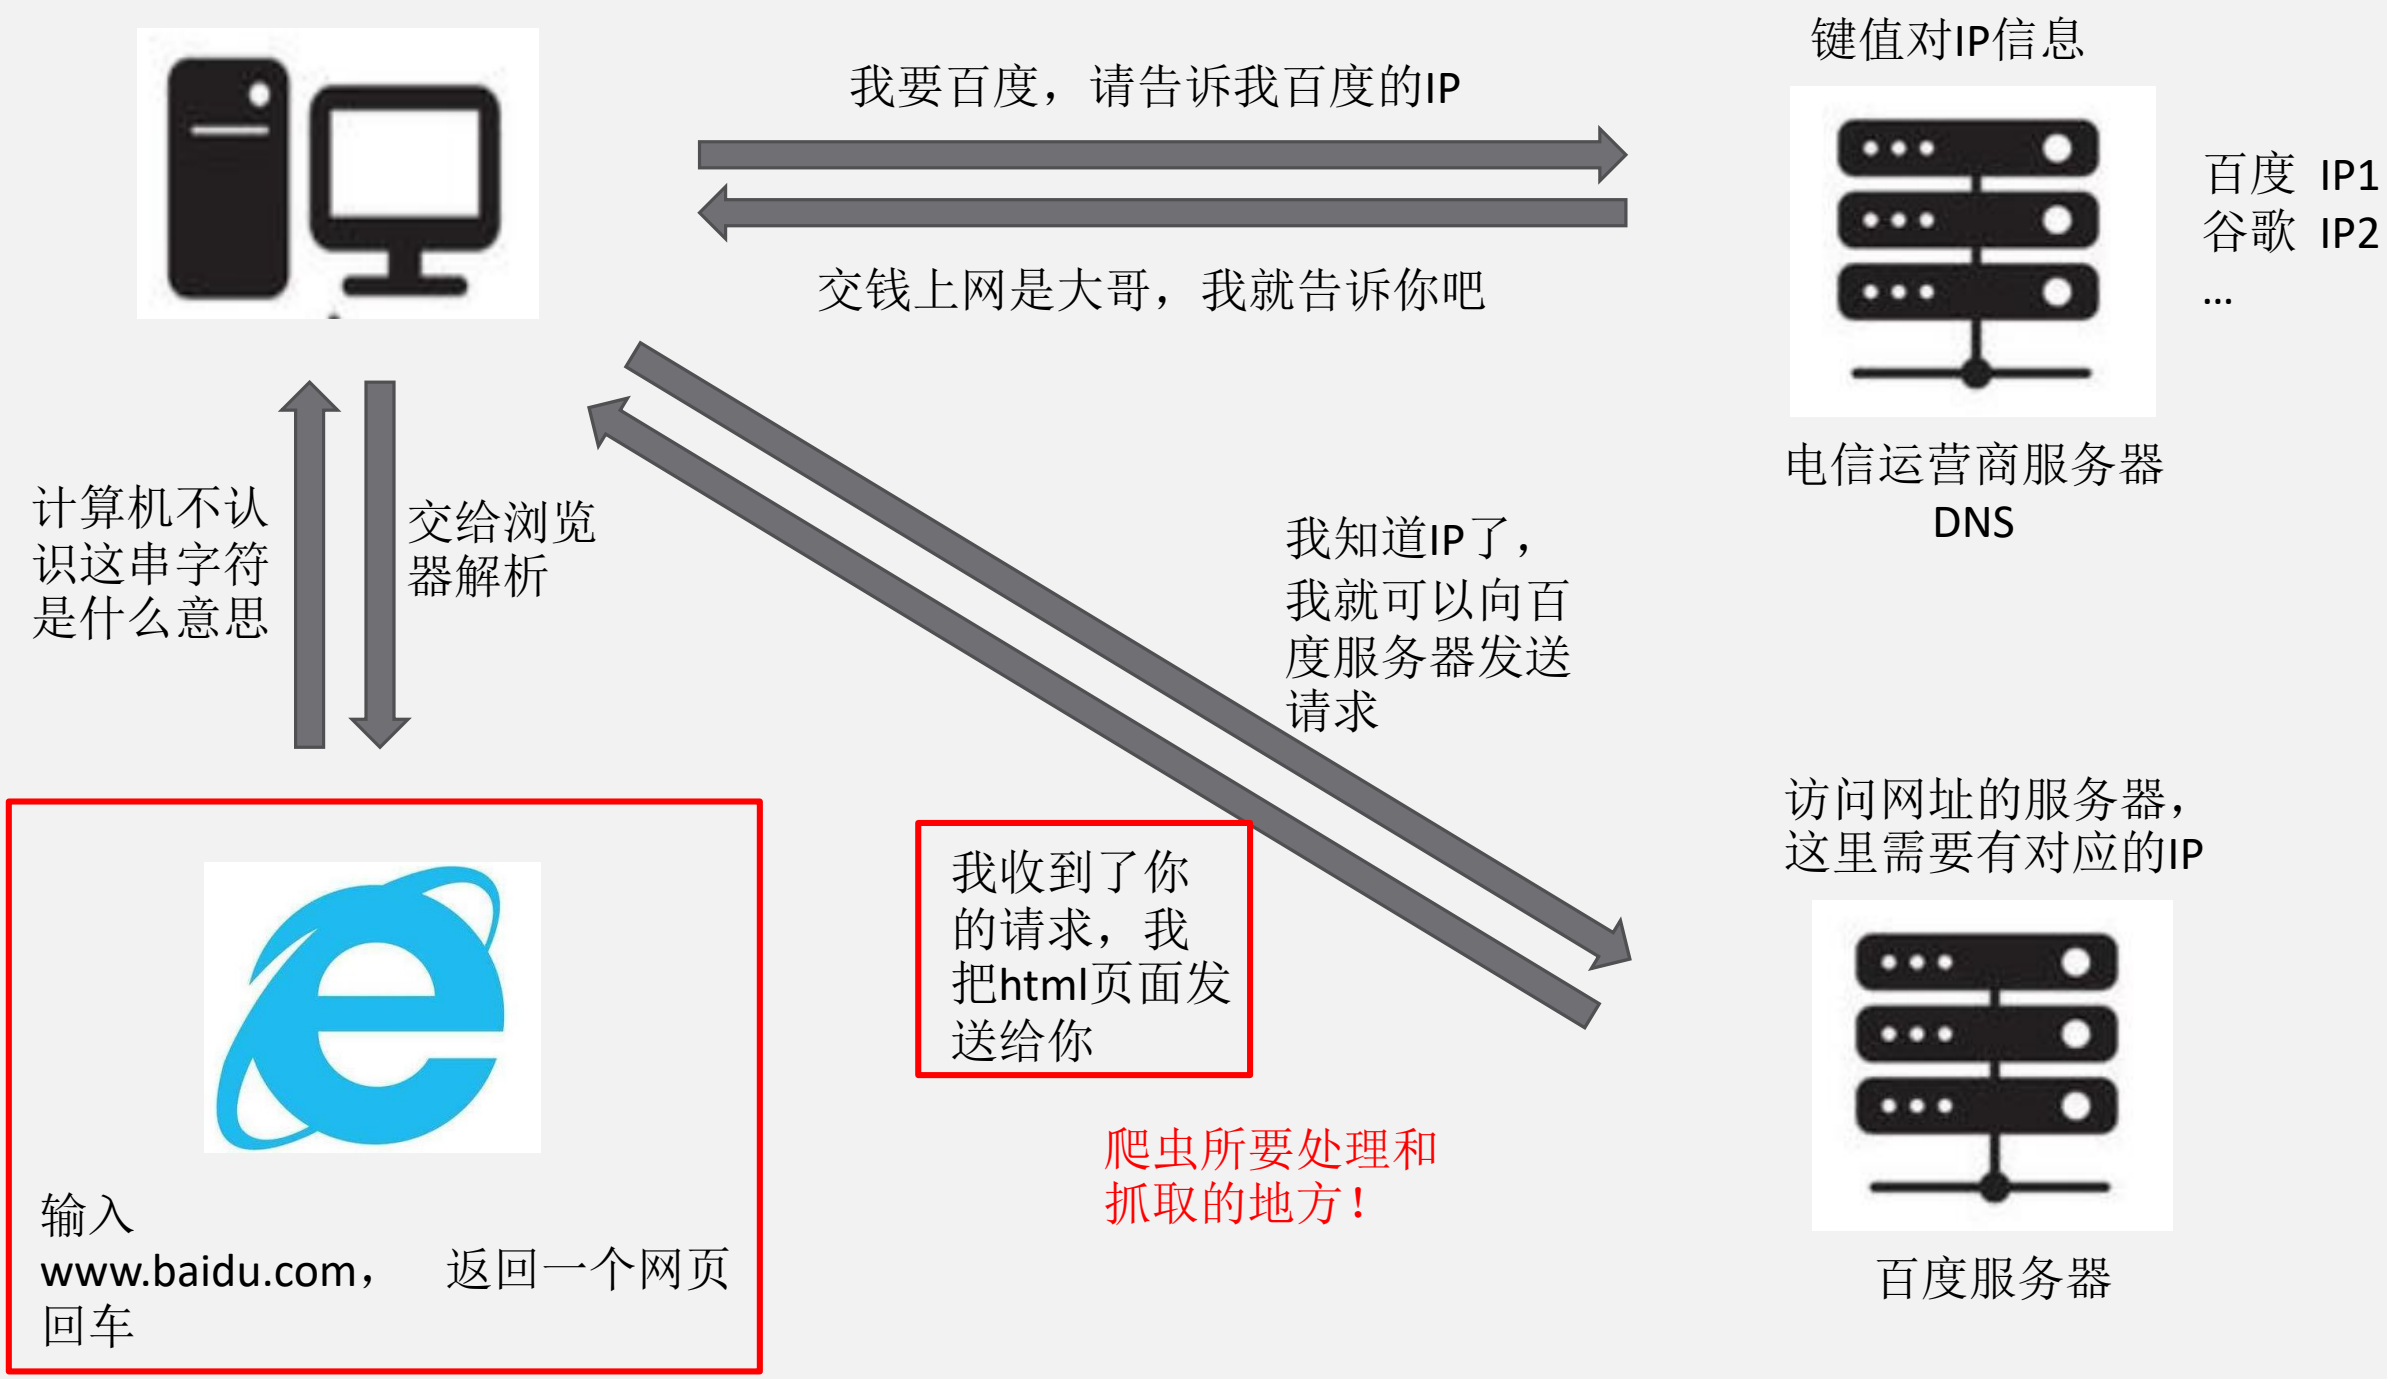
键值对IP信息
我要百度，请告诉我百度的IP
交钱上网是大哥，我就告诉你吧
百度 IP1
谷歌 IP2
...
电信运营商服务器
DNS
计算机不认识这串字符是什么意思
交给浏览器解析
我知道IP了，我就可以向百度服务器发送请求
我收到了你的请求，我把html页面发送给你
爬虫所要处理和抓取的地方！
访问网址的服务器，这里需要有对应的IP
百度服务器
输入www.baidu.com，回车
返回一个网页

现在想想，

为什么我们访问不了谷歌？

我们已知IP向网页的服务器发送了IP，即访问请求，服务器返回html。这个过程我们称为**网络请求，**也称为HTTP请求。

常见的协议主要有以下八种，其中GET和POST最常用

HTTP请求

请求方式	描述
GET	发送请求来获得服务器上的资源【比如请求百度的页面】
POST	向服务器提交资源让服务器处理【比如百度云盘上传资源】
HEAD	主要用来检查资源或超链接的有效性或是否可以可达、检查网页是否被串改或更新
PUT	向指定资源位置上上传其最新内容
DELETE	请求服务器删除某资源
CONNECT	HTTP/1.1协议中预留给能够将连接改为管道方式的代理服务器。
OPTIONS	允许客户端查看服务器的性能
TRACE	回显服务器收到的请求，主要用于测试或诊断

(1) GET请求：一般情况下，发送请求从服务器上获取资源，不会对服务器资源产生任何影响的时候使用GET请求。

(2) POST请求：向服务器发送数据（登录）、上传文件等让服务器处理，会对服务器资源产生影响的时候使用POST请求。

GET请求演示

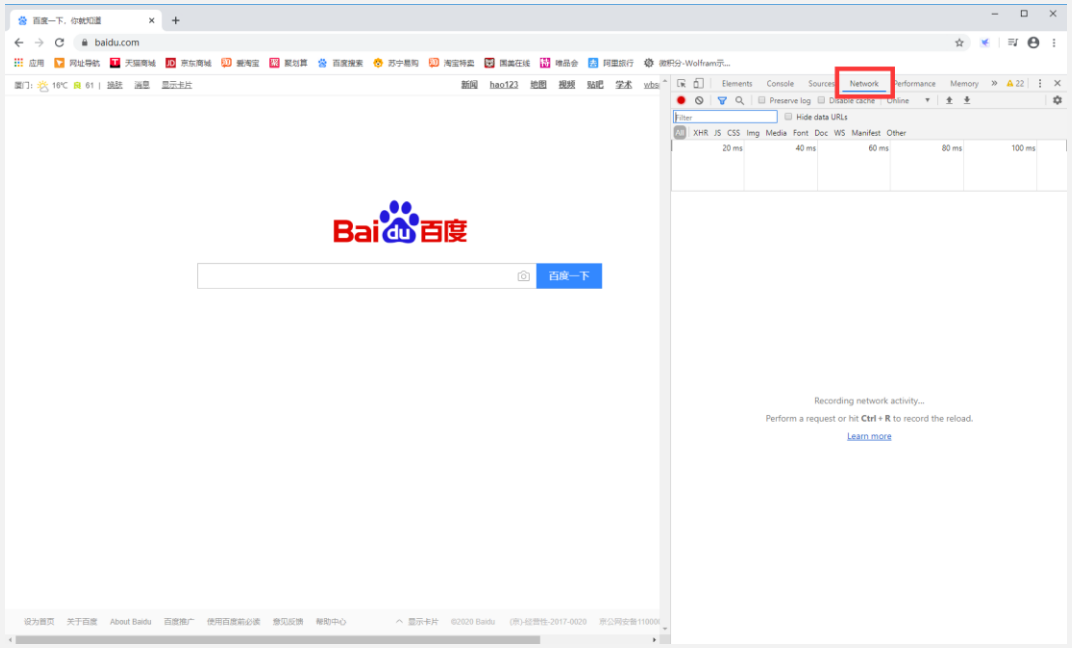

刷新下网页（F5）

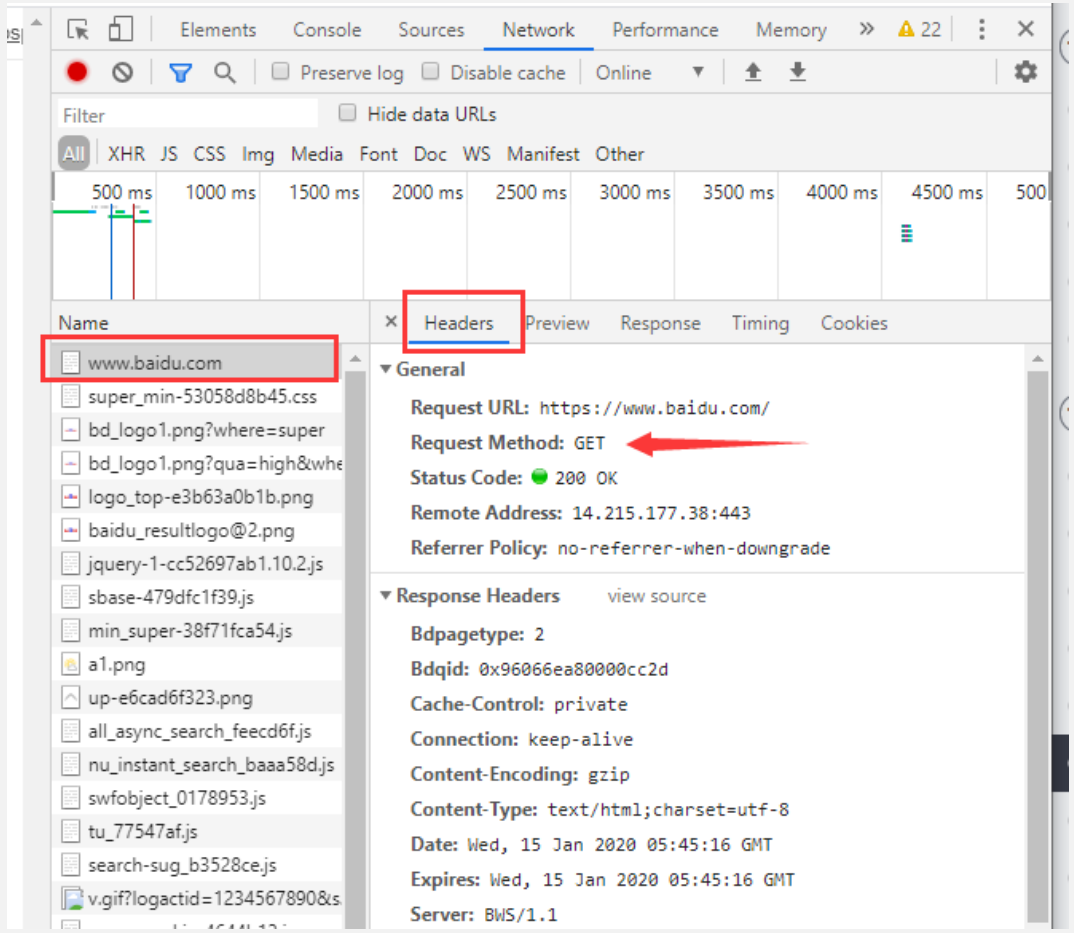

POST请求演示

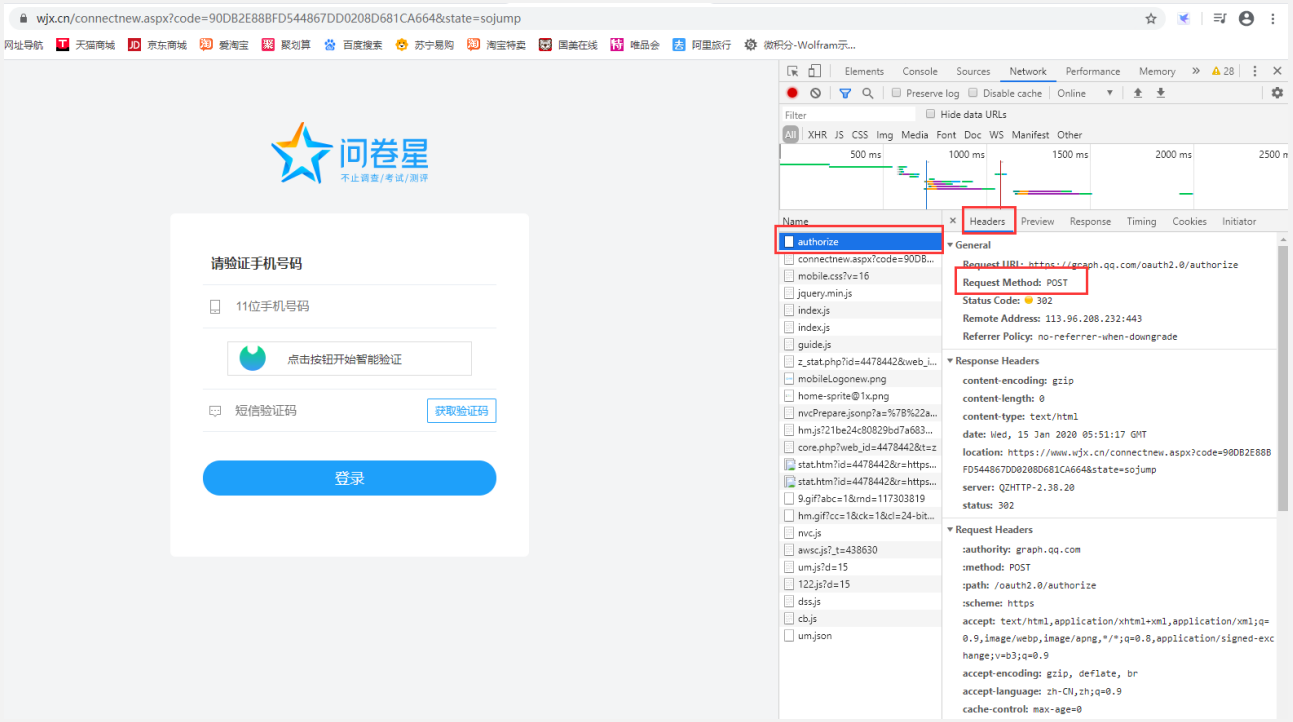

登录，上传文件，发表文章等对服务器产生修改或影响的，都会是POST请求

请求头常见参数

(1)User-Agent

浏览器的名称。向服务器发送请求时，服务器通过该参数了解请求是从何种浏览器发出，以便返回正确的信息。必须设定这个参数。不设置该参数，服务器就知道你是用python等工具在爬取数据，此时，服务器设置了反爬，就会拒绝你的请求

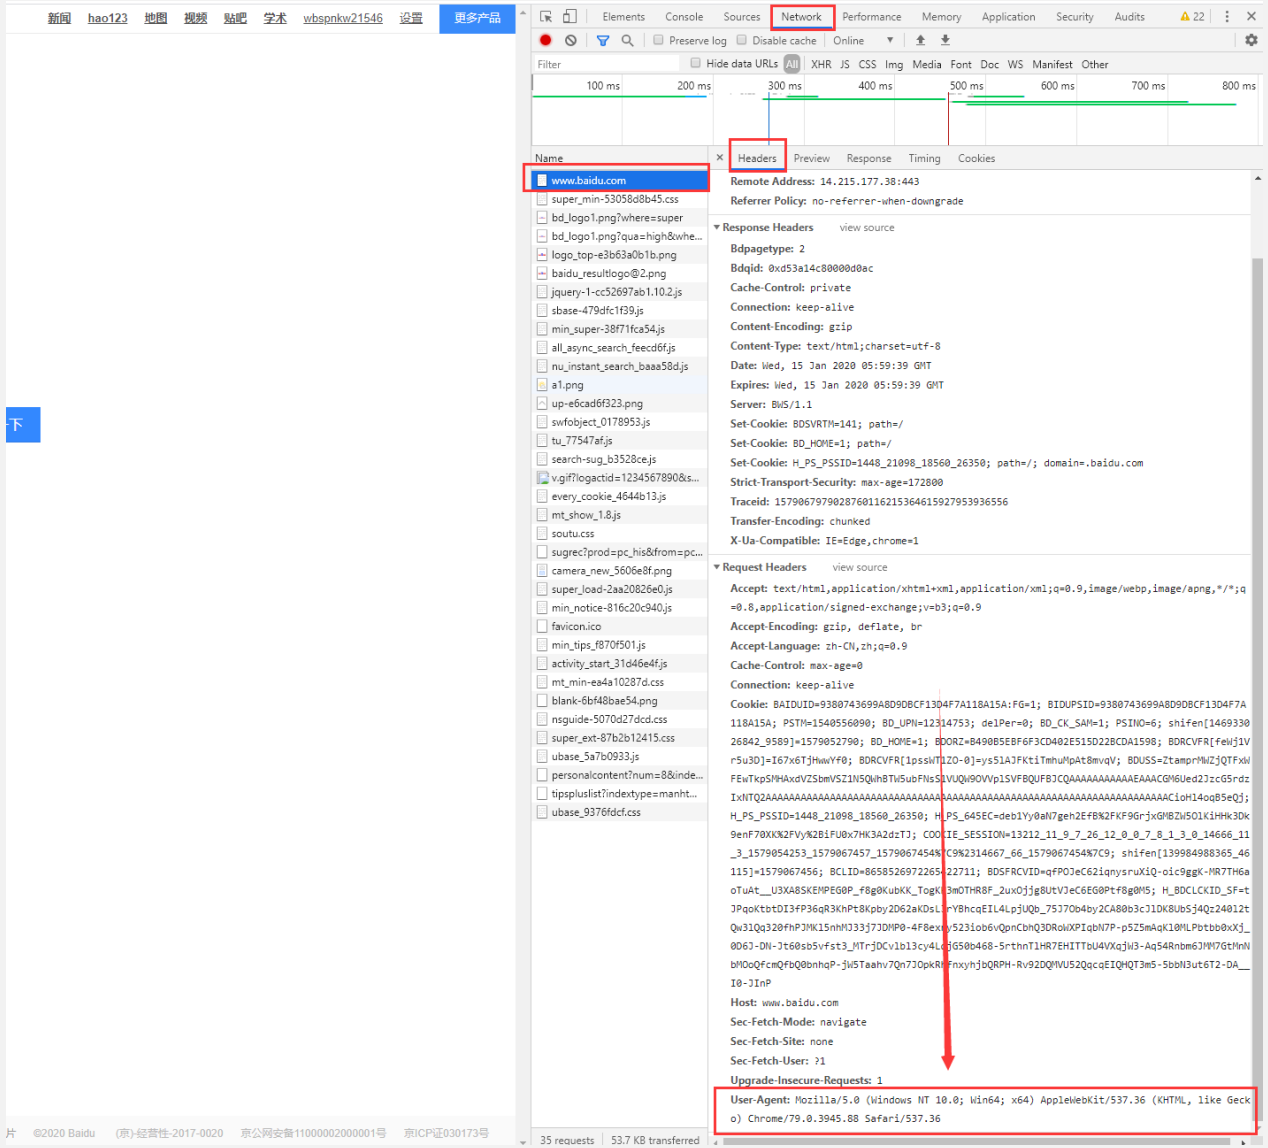

(2) Referer

表明网页是从哪个网站跳转而来。
有些网页只能从特定的链接跳转过来，如果不设置，一些网页就会监测到你是通过非浏览器方式试图获取他们的html页面，就不会返回数据。通过该参数便用来进行反爬虫设计，我们需要设定这个参数。

(3) Cookie

HTTP协议是无状态的。我们在浏览器上发送了两次请求，服务器不知道这两个请求是否来自同一个人。因此这时候就用Cookie来做标识。一般登陆后才能访问的网页，这个时候就需要发送Cookie信息。

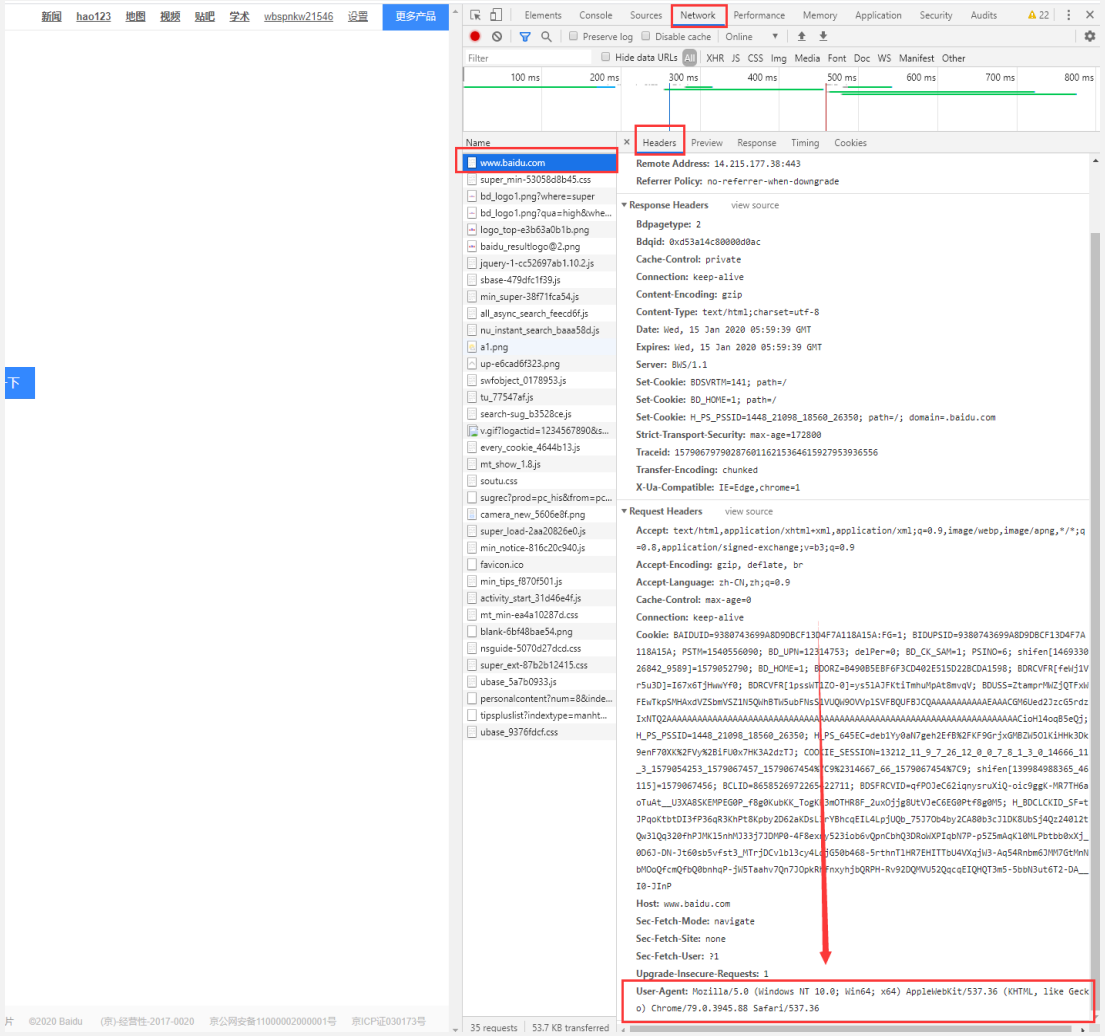

注：以上的信息，在爬虫时，复制粘贴就可以了。相当于我们用python“伪装”成了一个浏览器，一个活生生的人去访问服务器，得到html，并且在html中获取数据，这就是爬虫真正在做的事情。

bilibili.com/read/cv4322389

Anaconda3安装教程

学习 1-10 98阅读 10点赞 5评论

现在常见的关于python的编译器有很多，我总结下大概就是开发用pycharm，教学或者对于编程和计算机环境配置相对比较薄弱的就用Anaconda。

Anaconda的主要优势，或者说我想用它来进行大部分python的教学的原因主要有以下几点：

（1）Anaconda的安装是比较简单的，甚至是傻瓜的。其他的编译器对于小白或者刚入门的同学们也算是一种折磨吧

（2）Anaconda的环境配置相对简单

（3）Anaconda最主要的两个编译器Jupyter notebook和spyder，对于非程序员，软件或计算机的同学来说，或者对于老师在上课的展示效果来说是比较合适的。

Jupyter能够将实时代码，公式，可视化图表以Cell的方式组织在一起，形成一个对代码友好

Elements Console Sources Network Performance Memory Application Security Audits

Name | Headers | Preview | Response | Timing | Cookies

General

Request URL: https://www.bilibili.com/read/cv4322389
Request Method: GET
Status Code: 200 OK
Remote Address: 120.92.218.109:443
Referrer Policy: no-referrer-when-downgrade

Response Headers view source

Cache-Control: max-age=300
Connection: keep-alive
Content-Encoding: gzip
Content-Type: text/html; charset=utf-8
Date: Wed, 15 Jan 2020 06:05:33 GMT
Expires: Wed, 15 Jan 2020 06:10:33 GMT
jinkela: jinkela-article-server
Transfer-Encoding: chunked
Vary: Origin,Accept-Encoding
X-Cache-Webcdn: HIT from ks-sh-bgp-w-06

Request Headers view source

Accept: text/html,application/xhtml+xml,application/xml;q=0.9,image/webp,image/apng,*/*;q=0.8,application/signed-exchange;v=b3;q=0.9
Accept-Encoding: gzip, deflate, br
Accept-Language: zh-CN,zh;q=0.9
Cache-Control: max-age=0
Connection: keep-alive
Cookie: _uuid=EB2DC11A-AD26-EA31-32A0-1C0137F1317544417infoc; buvid3=57779F96-518A-4EDD-BD5A-F4C8BB5901F5155825infoc; CURRENT_FNVAL=16; stardustvideo=1; rpdid=|(umYRmk~~JR0J'ul~RRk~kY; im_notify_type_100682193=0; sid=jhtaao1z; laboratory=1-1; LIVE_BUVID=0cc31a0826f5b5acfe; 4a8233b425e6c; LIVE_BUVID__ckMd5=7323bf3ccde4ea09; CURRENT_QUALITY=80; DedeUserID=100682193; DedeUserID__ckMd5=8e1ac6f5ed22ee20; SESSDATA=15c634f0%2C1579614512%2C46e650c1; bili_jct=375721328d5ce726e860d74444457dc87; dy_spec_agreed=1; INTVER=1; bp_t_offset_100682193=344560973048432876
Host: www.bilibili.com
Referer: https://space.bilibili.com/100682193/
Sec-Fetch-Mode: navigate
Sec-Fetch-Site: same-site
Sec-Fetch-User: ?1
Upgrade-Insecure-Requests: 1
User-Agent: Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/79.0.3945.88 Safari/537.36

167 requests | 48.1 KB transferred

常见响应状态码

状态码	含义
200	请求成功
301	永久重定向，资源（网页等）被永久转移到其它URL 【www.jingdong.com --->>>www.jd.com】
404	请求的资源（网页等）不存在
500	内部服务器错误

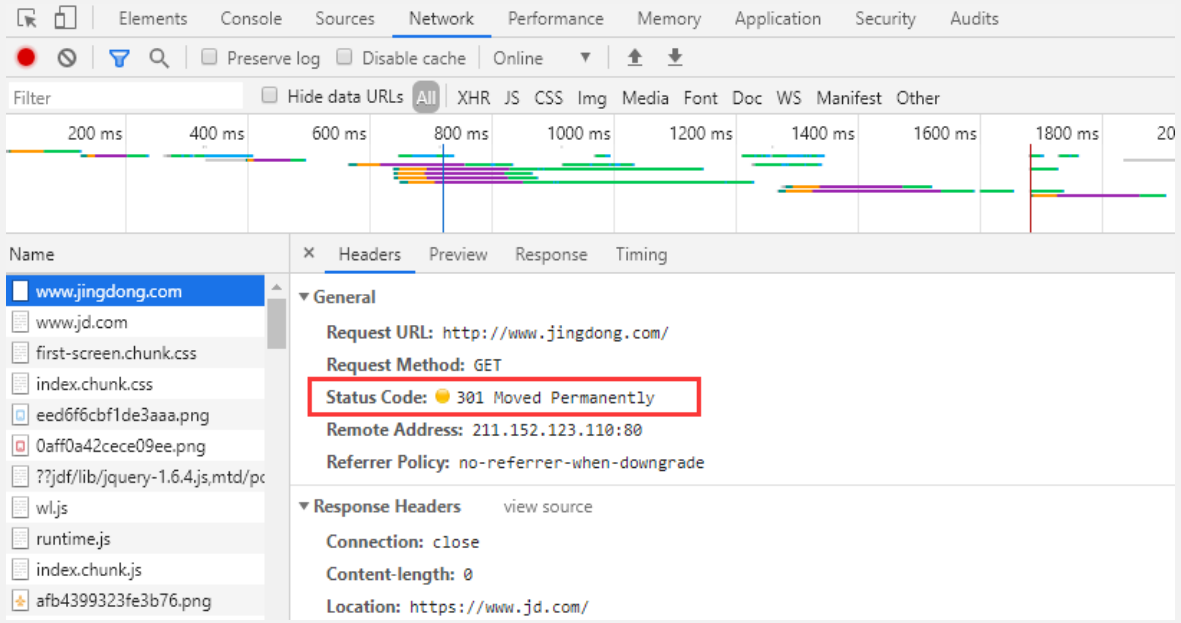

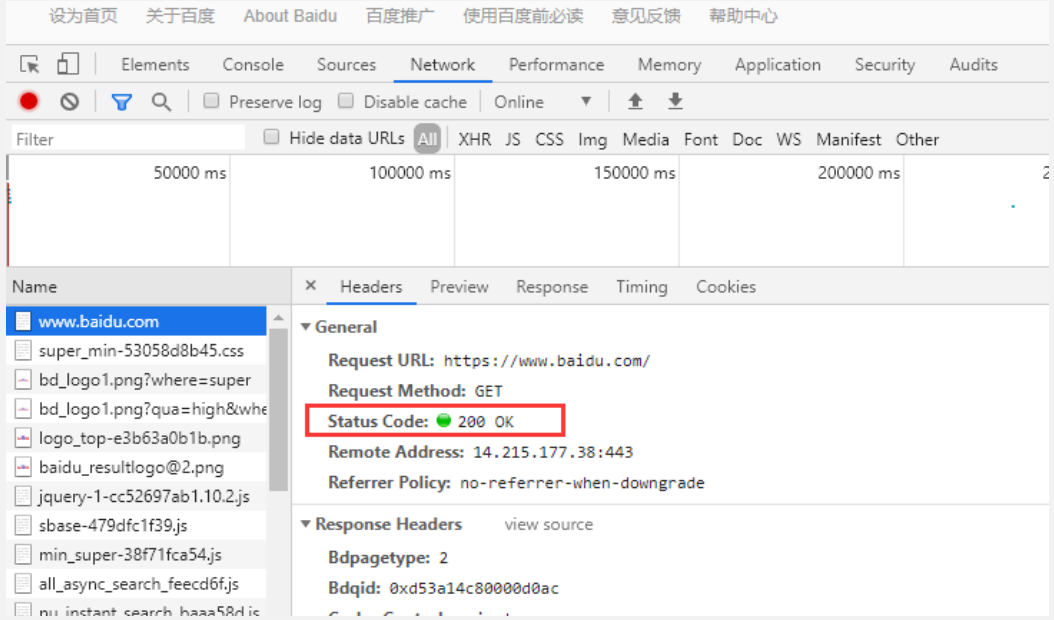

认识URL

- URL是Uniform Resource Locator的缩写，中文全称统一资源定位符，俗称网址。每一个信息资源在网上都有唯一的一个地址，这就是URL。

我们输入www.baidu.com，浏览器其实还帮我们做了一些事，比如我们输入的网址不满足URL的规则，浏览器会默默的帮我们补充上https://

我们来了解下URL的规则。

URL的组成

URL遵守以下的语法规则　　scheme://host:port/path/?query-string=xxx#anchor

scheme - 定义因特网服务的类型，即访问因特网的协议。常见的协议有 http、https、ftp、file。

<1>HTTP协议：超文本传输协议，是一种发布和接收HTML页面的协议。默认服务端口为80端口。
<2>HTTPS协议：是HTTP协议的加密版本，在HTTP下加入了SSL层。默认服务端口为443端口。
<3>FTP协议：文件传输协议。
<4>FILE协议：本地文件传输协议。

http为明文传输，不安全，容易被截取相关信息，如登录QQ时，别人窃取了你的登录信息。
https则是加密传输，相对安全。登录QQ时别人截取到的也是经过加密后的登录信息。
FTP，例如QQ在传输文件时，就遵循FTP协议
FILE协议则是本地文件访问过程中遵循的协议。如下载下来的网页，再打开，它的URL发生了变化。

host - 主机名，域名（比如：www.baidu.com）
port - 定义主机上的端口号（http 的默认端口号是 80；https 的默认端口号为443）

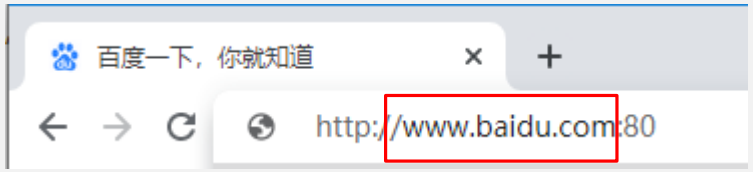

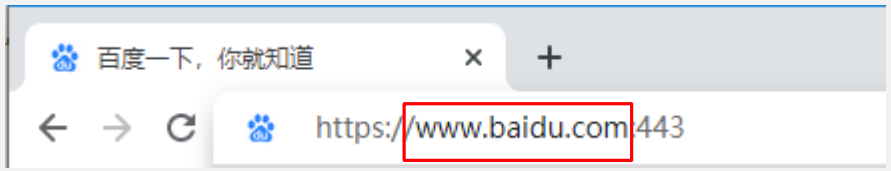

注：这里都跳转到了https协议下的地址，原因很简单，http是明文传输，服务器为了用户安全，将http自动跳转到https协议下。

path - 定义服务器上的路径（如果省略，则文档必须位于网站的根目录中）。

https://www.bilibili.com/read/cv4322389 标红部分即为路径

query-string - 定义文档/资源的名称。

https://www.baidu.com/s?&wd=番茄

https://www.baidu.com/s?&wd=%E7%95%AA%E8%8C%84

anchor-网页锚点，前端用来做网页定位。

谢谢聆听